

Relatório de verificação do projeto NetLab G1

Web scraping, diagnóstico de qualidade, métricas e validação de requisitos

Repositório: netlab-g1

URL remota: <https://github.com/fregulha/netlab-g1-web scraping.git>

Branch: main...origin/main

Commit: 2a69041

Data do relatório: 17/09/2026 18:21:55

Resumo executivo

O repositório contém a rotina de extração em Python com BeautifulSoup, testes automatizados, dados de amostra, métricas e documentação. A implementação cobre boa parte dos requisitos solicitados, com destaque para robustez de parsing, deduplicação, logs, CSV/JSON e validação automatizada.

- A rotina de coleta foi revisada para lidar com HTML dinâmico, campos ausentes e respostas inconsistentes.
- A deduplicação e a separação de registros em quarentena reduzem erros de interpretação e ruído no conjunto final.
- O projeto mantém rastreabilidade operacional por meio de logs, metadados e arquivos de evidência.

Arquivos principais

- scraper.py: rotina de coleta, parsing, deduplicação e exportação
- evaluate.py: métricas de completude, cobertura e qualidade
- tests/test_scraper.py: suíte automatizada de validação
- README.md: documentação de diagnóstico e execução
- data/coleta_multilotes/resultados.json: base coletada em múltiplos lotes
- data/metricas_multilotes.json: métricas produzidas
- docs/llm.md: proposta de uso de LLM

Verificação de requisitos

- Identificar problemas do código atual: STATUS = OK.
- Corrigir a rotina com Python + BeautifulSoup: STATUS = OK.
- Atualizar seletores e paginação: STATUS = PARCIAL, com validação em snapshots locais.
- Coletar título, URL, resumo, data e metadados: STATUS = OK.
- Tratar falhas de conexão, HTTP e campos ausentes: STATUS = OK.
- Evitar duplicados: STATUS = OK.
- Organizar o código: STATUS = OK.
- Salvar em CSV/JSON: STATUS = OK.
- Testes automatizados: STATUS = OK (25 testes aprovados).
- Documentação: STATUS = OK.

- Uso de LLM: STATUS = OK.
- Avaliação de qualidade: STATUS = OK.

Dados e evidências

- 30 URLs únicas após deduplicação
- 26 notícias e 4 vídeos na base validada
- título, URL, resumo e data exibida presentes em 30/30 registros
- 5 critérios de qualidade avaliados e documentados
- resultado final validado com pytest (25 testes)

Conclusão

O projeto está em um estado consistente para uso acadêmico e seletivo. O principal ponto pendente é a validação de paginação online real em ambiente de navegador, mas a base local, a correção do parser e a validação automatizada já demonstram robustez funcional.